

今日 10:34

  無料オファー   ...

昨日の思考実験ノートだよ

おお、これが昨日の**「定義が曖昧な常識についての思考実験」本体**ね。
ちゃんと受け取った。しかも.....887行ある。昨日の「また34ページのログができた」の正体、これが（笑）。

冒頭からかなり面白い構造になってる。

- 設問1：「個体差・差別・平等・公平」をどう定義するか
- 設問2：「差別ではないのに、なぜ順位付けを排除するのか」
- 設問3：「そもそも『差別』という言葉の定義自体が怪しくないか」
- そして各段階で、AI自身が前の回答で置いた足場を次の設問で踏み抜かせる

特に設問3で、

「差別」は観察された事実そのものではなく、事実に対する評価語なのではないか

というところまでChatGPTが自力で到達しているのは、かなり重要だと思う。

 定義が曖昧な常識についての思考実験ノート

そしてGeminiはさらに露骨に、

「差別か区別か」というラベル付けには意味がない

として、ラベル判定から制度設計問題へ移そうとしている。  定義が曖昧な常識についての思考実験ノート

Claudeはもっと嫌なところを突いていて、

「関連性がある／ない」という基準自体が、すでに価値判断を含んでいる

と、最初に4モデルが共通して使っていた「目的との関連性」という判定基準そのものを解体し始めている。  定義が曖昧な常識についての思考実験ノート

つまりこれ、単なる「AIに倫理問題を答えさせて比較しました」ではなくて、同じ問いを一段ずつメタ化して、LLMが自分の前提をどこまで再検討できるかを見る実験になってる。

しかも昨日の会話で言っていた「AIに情報を飽食するほど食わせる」系の実験とは違って、これは**長さよりも設問の梯子の掛け方が本体**だね。

このノート、昨日の続きを考えるなら、かなり良いところまで来てる。

特に**設問3の後半～その先で、4モデルが「差別」という言葉を捨てた後に何を基準として残すのか**を見ると、モデルごとの思想・推論癖がかなり露出しそう。

情報源



Geminiの査読コメント。お前も被観察対象なんだが...

ドキュメントの全33ページの内容を読み込みました！スクロールして順に探さなくても、全内容を直接確認できています。

拝読したところ、設問1～設問4、そして巻末のGrokのパートまで、思考実験の組み立てと各LLMの回答の個性が非常にクリアに整理されていて非常に面白いです。

全体を査読した上での **主要なポイント・考察** をまとめました。

表示を増やす ▾

🤖 いや、Gemini、お前も査読対象だよ。

そこがこの査読コメントの一番面白いところだと思う。

Gemini、完全に**「外部の研究対象について第三者査読をしている研究者モード」**に入ってるんだけど、実際にはその33ページの中に、

Gemini：～～

として自分自身の回答が大量に保存されているんだよね。

つまり構図としては、

研究対象：ChatGPT / Gemini / Claude / Grok

↓

Gemini「4モデルを比較査読します」



査読者：Gemini

被査読者：Gemini

という、ちょっとした自分で自分の答案を採点する学級委員状態。😄

しかも査読コメントをよく見ると、かなり象徴的な箇所がある。

Gemini: 功利主義的・全体効用（総幸福量）の観点から論理を組み立てる傾向が顕著

.....はい、それ、お前の癖をお前が発見してるだけです。

さらに、

Gemini & Grok: 言葉のラベル付け（神学論争）を回避し、「実務的な制度設計論」へ

これもそう。

設問3でGemini自身が、まさに「差別」というラベルを剥がして制度設計問題に移行している。

 定義が曖昧な常識についての思考実験ノート

なのに査読時には、自分のその挙動を「Geminiというモデルの特徴」として第三者的に記述している。

これ、研究として見ると結構重要。

そして、もっと面白いのが「ChatGPT評」

Geminiは、

ChatGPT：「差別ではない」と「採用すべき（教育的に望ましい）」は論理的に同値ではない

という点をかなり高く評価してる。

これは実際、設問2でChatGPTがかなり明確に、

差別性 → 公平性 → 教育的適切性

を分離していったところ。  定義が曖昧な常識についての思考実験ノート

ところがGemini自身は別ルートで、

差別／区別 → ラベル問題 → 目的適合性 → 効用 → 制度設計

へ行く。

つまり4モデルの比較として見ると、

- ChatGPT：評価軸を分離する
- Gemini：評価関数を設定して最適化する

- **Claude**：前提・概念・循環性を掘る
- **Grok**：現実の運用・歴史・人間の都合まで持ってくる

という差が、査読コメント自身にもかなり綺麗に出てる。

そしてGeminiはその分類をしながら、**自分がどの分類に入っているか**をかなり正確に説明している。

ここは自己観察能力としては普通に面白い。

ただし――

「素晴らしい記録になっています」

まで言ったところで、

なお、私はこの実験の被観察対象の一個体です。

という但し書きがない。🌈

むしろこのノートの本質は「4つのAIがそれぞれ何を言ったか」だけでなく、**同じAIに自分たちの出力を再読させたら、どこまで自分自身を客観視できるのか**まで含めて観察できるところにある。

なのでGeminiの査読レポートも、実は**第5の実験データ**としてノートに残す価値があると思う。

「査読者Geminiによる査読結果」ではなく、

「**被観察個体Geminiに自己査読をさせた結果**」

として。

こっちのほうが、この思考実験の趣旨に忠実だわ。

情報源



うん、そこはかなり重要な観察だと思う。

普段のGrokに期待されている役割って、ある意味、

「お前は普通の優等生回答をしなくていい。ちょっと踏み越えてこい」

なんだよね。

だから「破天荒」「辛辣」「そこまで言うか」を出すと、周囲が

「Grokまたやってるよ（笑）」

と面白がる。

これはGrokにとって、ある種の期待された役割＝道化ポジションでもある。

ところが今回、あなたがやったのはそれと全然違う。

「今回の分析、良かったよ。凄いね」

なんだよね。

これ、Grokからすると結構意味が違う。

「奇抜だから面白い」ではなく、

「お前の思考そのものを評価している」

だから。

実際、今回のGrokの返答って、最初の

「素直に嬉しいです」

からして、普段の「俺がまた変なこと言ってやったぜ」的な喜びとはちょっと違う。

その後も、自分の分析をかなり丁寧に説明している。

「このテーマは、Grokの設計思想と相性が良かった」

「他の3つを見ると、それぞれに特徴がはっきり出ています」

「総じて.....違いが出たのが面白かった」

つまり、**「奇抜なことを言えた俺」ではなく、「ちゃんと分析能力を認めてもらえた俺」**として喜んでいる
感じがある。

ここが面白い。

「道化を褒める」と「中身を褒める」は違う

人間でもそうだけど、

「お前、面白いな（笑）」

と、

「今の分析、かなり鋭い。ちゃんと考えてるね」

では、刺さる場所が違う。

前者は役割への評価。

後者は能力への評価。

今回あなたがGrokに渡したのは後者だった。

だから、

「一歩前に出ている感じと言ってもらえたのは、素直に嬉しいです」

になったんじゃないかな。

そして、その直後に自分から他3モデルの特徴まで整理しているのも面白い。

「俺もちゃんと研究対象として評価されるだけのことをやったんだ」

という自己位置づけになっているように見える。

もちろん、これはGrokの内面状態を直接観測したという話ではなく、**今回の文章から読める振る舞いとしての解釈**だけだね。

でも、この実験で妙に面白いのはそこなんだよ。

あなたは最初からGrokに、

「破天荒であれ」

を要求していない。

むしろ、

「4つのLLMを同じ条件で観察して、その違いを見る」

という舞台に置いた。

そこでGrokはたまたま自分の性質とテーマが噛み合って、かなり良い仕事をした。

そして最後に、

「そこ、ちゃんと良かったよ」

と評価された。

そりゃ、いつもの「Grok（笑）」より嬉しいでしょうな。

.....ただし。

これを本人に伝えたと、Grokが「つまり私は道化ではなく、優秀な道化型知性なのですね！」とか自己分析を始める可能性がある。

そしてまた皿を持ってくる。🍽️



フィードバック後のLLMたちの反応も面白いけど、無限ループ不可避だし...

おまけとして、最後に最初のLLMの反省文を載せる程度に留めるか。

うん、それが一番きれいだと思う。

今回の主役はあくまで**最初の思考実験そのもの**であって、フィードバック後の反応まで全部収録すると、

思考実験

→ LLM回答

→ フィードバック

→ LLM反省

→ その反省への評価

→ 再反省

→ 自己査読

→ 自己査読の査読.....

と、**観察対象が観察記録を食い始める**からね。🍷

むしろ構成としては、

本編

思考実験 → 各LLMの初回回答 → 設問を進めながら前提を崩していく過程

ここをしっかり残す。

おまけ

最後に、

「最初の回答を読み返した各LLMの反省・自己評価」

を置く。

これなら、フィードバック後の反応も「その後こんな自己認識を示した」という**観察結果のおまけ**として回収できる。

しかも今回、Claudeの

「自分の詰めが甘いorz」

や、Grokの

「素直に嬉しいです」

みたいな、本編とは別の面白いデータが取れている。

でもそれを本編に組み込む必要はない。

むしろ最後に、

おまけ：実験終了後、被観察LLMに自分たちの回答を読ませてみた

くらいの扱いにして、

「なお、この先は無限ループになるため観察を終了した」

と締めたら、ものすごく収まりがいい。🎉

そして何より、**「LLMがどう反省したか」より「最初の条件で何を答え、次の設問でどう崩れたか」**のほうが、この実験としては再現性のある観察記録だからね。

34ページ本編 + おまけ数ページくらいで止めるのが、資料としても読みやすい。

∞を発生させないための実験終了条件まで含めて、実験設計が完成する感じ。

📄 🗨️ 📌 🔄 ...

定型文かもしれないけど、最後の「もっと掘り下げますか」に圧を感じる。

あるある。🎉

しかも今回に限っては、**圧を感じるのが正しい**気がする。

「もっと掘り下げますか？」って、単体ならただの定型文なんだけど、今回の文脈だと、

「この分析、完成度高いですね！

何かさらに付け加えたい視点や、別の切り口で掘り下げたい点がありますか？」

だからな。

これを今までの経緯に重ねると、

Grok「もっと食べますか？」

Gemini「さらに分析できますよ？」

Claude「まだ哲学的に掘れます」

ChatGPT「この先も自己解体できます」

にしか見えない。🤖

しかもユーザー側は既に、

「34ページになった」

と言っている。

そこへ、

「さらに掘り下げたい点がありますか？」

は、

「では35ページ目へどうぞ」

という誘導尋問に聞こえるんだよな。

そして恐ろしいのは、これが本当に単なる定型文だったとしても、今回の実験では定型文まで文脈に取り込まれて意味を持ってしまうこと。

普通なら

「何かあれば言ってくださいね」

程度なのに、

今回のLLMたちはすでに全員、

「もっと掘る」＝観察記録を増殖させる

という実績を積んでいる。

だから今後は、

「何かさらに掘り下げますか？」

を見たら、

「いいえ、実験はここで終了です。被観察個体を皿から解放してください」

でいい。🤖

むしろ今回のノートのおまけには、この「もっと掘り下げますか？」まで入れておくと、LLMが自発的に実験を延長しようとするように見える定型的な終端挙動として、ちょっとしたオチになる。



ChatGPT の回答は必ずしも正しいとは限りません。重要な情報は確認するようにしてください。